

מטלת סוף סימסטר – מבוא לאקונומטריקה

מרצים – ד"ר רועי לוי, פרופסור אנליה שלוסר

מגישים – עומרי דן, איתי קריסטל-טננבאום

חלק א:

1. במשך שנים רבות, גופי מחקר ואוניברסיטאות מנסים למצוא דרכים לגרום לתלמידים למקסם את הפוטנציאל האקדמי שלהם. במאמר מתואר מחקר שבו בדקו שאלו זו – כיצד ניתן לעזור לסטודנטים בשנה הראשונה שלהם בקולג' להשיג את ההישגים הגבוהים ביותר שבאפשרותם להשיג. במחקר, חילקו את הסטודנטים המשתתפים לארבע קבוצות – קבוצה המקבלת תמיכה אקדמית בלבד (SSP), קבוצה המקבלת מוטיבציה כלכלית בלבד (SFP), קבוצה שנתמכת אקדמית וגם מקבלת תמריצים כלכליים להצלחתם (SFSP), וקבוצת ביקורת.

$$grades = \beta_0 + \beta_1 academicsupport + u \quad .2$$

הרגרסה מהסוג הזה אכן מראה **התאמה** בין תמיכה אקדמית לציונים של סטודנטים, עם זאת, בכך שמתחשבים רק במשתנה מסביר אחד (תמיכה אקדמית), ומשמיטים מספר רב של משתנים נוספים אשר מתואמים עם המשתנה המוסבר (הם נכללים בתוך ההפרעה המקרית u), מאבדים חלק משמעותי מהמשתנים החשובים המשפיעים בנוסף על הציונים (כמו רמת IQ, מצב סוציו אקונומי וכו'). לכן אנחנו נקבל משתנה β_1 מוטה, אזו הרגרסה כזו אינה אומדת את ההשפעה הסיבתית של תמיכה אקדמית על ציונים.

דוגמה להטיה של β_1 זה רמת רצון הסטודנט להצליח (נסמנה ב-motivation). נראה כי במודל אשר כן לוקח בחשבון motivation יראה כך –

$$grades = \tilde{\beta}_0 + \tilde{\beta}_1 academicsupport + \tilde{\beta}_2 motivation + v$$

נראה כי במודל שנאמד, β_1 יהיה מוטה כלפי מעלה:

נשער שיש ל-motivation השפעה חיובית על ציוני סטודנטים, כך ש- $\tilde{\beta}_2 > 0$, ושברוב המוסדות, תמיכה אקדמית ניתנת יותר לסטודנטים בעלי מוטיבציה, שכן נותנים לבקש יותר עזרה ולהשתתף יותר. לכן נצפה לשונות משותפת חיובית - $\widehat{Cov}(academicsupport, motivation) > 0$ בנוסף, שונות הסטודנטים שקיבלו תמיכה כלכלית גדולה מאפס (אחרת דגמנו רק סטודנטים עם בדיוק אותה כמות תמיכה כלכלית, ולא ניתן להריץ ככה רגרסיה) אז מנוסחת ההטייה:

$$bias(\beta_1) = \tilde{\beta}_2 \frac{\widehat{Cov}(academicsupport, motivation)}{\widehat{Var}(academicsupport)} > 0$$

נוסף על כך, מדובר במשתנה Dummy אשר בודק בצורה בינארית האם התלמיד קיבל תמיכה אקדמית או

לא, כאשר יש משמעות רבה לסוג התמיכה, כמות התמיכה ואיכותה, ולדעתנו יש להוסיף טווח של תמיכות אקדמיות מסוג שונה על מנת להראות בצורה שקופה ואמיתית האם יש קשר סיבתי בין תמיכה אקדמית לציוני התלמידים.

3. בניגוד למחקרים שתוארו למעלה, בהן יש רק משתנה אחד בינארי של תמיכה אקדמית כן/לא. במחקר הספציפי שאנו עובדים עליו, יש חלוקה למספר קבוצות שונות. כל הקבוצות קיבלו את התמיכה המתוארת בשנה הראשונה לתואר האקדמי שלהם, ונמדדה ההשפעה של התוכנית אליה הם שויכו באותה שנה, ובשנה העוקבת.

(1) קבוצה שמקבלת תמיכה אקדמית בלבד - SSP. קבוצה זו קיבלה ליווי ותמיכה אקדמית מסטודנטים בוגרים ובנוסף שעות הוראה פרטניות מיועצים שעברו הכשרה לנושא. בנוסף על כך הוצעו לסטודנטים בקבוצה זו קבוצות למידה המחולקות לפי קורסים ספציפיים (FSG).

(2) קבוצה שמקבלת תמריצים כלכליים בלבד - SFP. קבוצה זו קיבלה תמריצים כלכליים בשנה האקדמית הראשונה שלהם, אשר ניתנת בצורה קטגוראלית, כאשר מחלקים את התלמידים לפי ההישגיים התיכוניים שלהם לארבע תתי-קבוצות, כשלכל קבוצה הוצאו תגמולים זהים ומטרות מותאמות לפי קבוצה. החלוקה התבצעה בצורה הבאה :

Lowest Quartile	2nd Lowest Quartile	2nd Highest Quartile	Highest Quartile
B – 5000\$ C+ – 1000\$	B+ – 5000\$ B – 1000\$	A- – 5000\$ B – 1000\$	לא השתתפו בתכנית

(3) קבוצה שמקבלת תמיכה אקדמית וכלכלית - SFSP. בעבור קבוצה זו הוצעו השירותים שניתנו לשתי הקבוצות הקודמות גם יחד.

(4) קבוצת ביקורת - על מנת לראות בצורה טובה את השפעת התכנית, נלקחה קבוצת ביקורת אשר לא השתתפו בתכנית, באותה שנה ובאותו מוסד.

הקבוצות חולקו בצורה רנדומאלית, נתאר בשאלות הבאות את אופן החלוקה והביקורת על החלוקה עצמה.

4. ניסוי מבוקר צפוי לפתור את בעיית ההטייה (אי קיום ההנחה הרביעית) באמידת הקשר בין תמיכה אקדמית או כספית לבין הישגי הסטודנטים, זאת משום שבניסוי כזה ייבחרו הסטודנטים מצד אחד בצורה אקראית¹, ובנוסף יבוצעו בקרות שימנעו מצב בו קיימת הטייה מובנית בתוך הנתונים (לדוגמא אם בקבוצה של התמיכות האקדמיות, יהיה רוב של תלמידים אשר מגיעים עם ציונים גבוהים צפויה הטייה כלפי מעלה של קבוצה זו, והנתונים יהיו מוטים).

¹ iid - Independent and identically distributed random variables, ensures that each variable behaves independently, the probability distribution is similar, which simplifies statistical analysis.

ניסוי בצורה הזו ימנע סיטואציה כזו וידאג לחלק את המשתנים הנ"ל בצורה שווה בין הקבוצות, ובכך שאריות הרגרסיה לא יקיימו התאמה עם המשתנים המסבירים - $E(u|x_i) = 0$

חלק ב:

1. נסכם בטבלה את ממוצע משתני הרקע בכל אחת מהקבוצות, ושל כלל המדגם.

משתני רקע	ביקורת	SSP	SFP	סה"כ
אישה	0.5727	0.5563	0.5988	0.575
ממוצע ציונים בתיכון	78.88	79.007	79.484	79.0033
גיל	18.264	18.181	18.1976	18.24
שפת אם של האם היא האנגלית	0.685	0.725	0.7267	0.6988

2. החלוקה נעשתה באופן רנדומלי, וכך נצפה שממוצעי משתני הרקע של כל קבוצה יהיו דומים. כך באמת קיבלנו, שינויים די קטנים בין הממוצעים, אם כי יש כמה הבדלים קצת יותר משמעותיים – למשל שפת האם של האם בין קבוצת הביקורת לקבוצת SSP. ממוצעים אלה מראים את מידת הקיום של ההנחה הרביעית, ושאכן החלוקה באופן רנדומלי הביאה לקבוצות זהות מבחינת משתני הרקע. נראה שבממוצע כ-58% מהסטודנטים הן נשים, כשנכנסים לקולג' הגיל הממוצע הינו 18.24, ממוצע ציוני תיעון הוא 79.0033, ושפת האם של האם היא האנגלית אצל כ-70% מהתלמידים. לדעתנו, אין הבדל משמעותי בין אחוז הסטודנטיות לסטודנטים בין ישראל לבין תוצאות המדגם, כך גם לגבי ממוצע ציונים בתיכון. בישראל השפה הלאומית הינה עברית (ולא אנגלית כפי שמתאים לאוכלוסייה במדגם) - לכן אם נתייחס לאחוז הסטודנטים בישראל ששפת האם של האם שלהם היא עברית, מכיוון שבארה"ב בדומה לישראל יש אוכלוסיות אתניות רבות ומהגרים רבים, לדעתנו כ-70% דומה למה שמתקבל בישראל.

לעומת זאת, ההבדל העיקרי בין תוצאות המדגם לישראל יהיה ממוצע גיל כניסה לאקדמיה. בארה"ב קיבלנו גיל של כ-18.24, כיוון שלרוב מסיימי תיכון מתחילים ללמוד בשנה שאחרי. לעומת זאת, בישראל, רבים משרתים בצה"ל או מתנדבים לשנות שירות, או שירות לאומי. לכן, ככל הנראה, גיל הכניסה לאוניברסיטה מבוגרת בהרבה מ-18.24, ולהערכתנו באזור 22-25. הבדל זה, לדעתנו, עשוי להוסיף עוד משתנים רלוונטים אם היינו עושים מחקר דומה בישראל, כמו למשל – חוויות טראומטיות במהלך השירות הצבאי, ועוד.

3.

נסן את המדגם לכלול רק את קבוצת הביקורת ואת הקבוצת הסטודנטים שהוקצו ל SSP על מנת לוודא שהסטודנטים חולקו בצורה אקראית ושוויונית מבחינת משתני הרקע שאנו בודקים. נרץ את המודל LPM הבא, כשנרצה לקבל ש $\beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$ בצורה מובהקת, כשמסמעות המקדמים הינה ההבדל בהסתברות בנקודות אחוז שסטודנט ימצא ב SSP לכל משתנה, כשקטגוריית הבסיס היא ההשתייכות לקבוצת הביקורת (הסטודנט בקבוצת הביקורת $\Rightarrow SSP_Offer = 0$).

$$(a) \text{ SSP_Offer} = \beta_0 + \beta_1 \text{age} + \beta_2 \text{female} + \beta_3 \text{english} + \beta_4 \text{GPA} + u$$

מכיוון שהיינו רוצים שלא יהיה ניתן "לחזות" לפי משתני הרקע את הקבוצה אליה ישתייך הסטודנט, נרצה שהשינוי בהסתברות להימצא בקבוצת SSP תהיה 0.

כפי שנלמד בכיתה, ידוע שבמודל LPM הנחת ההומוסקדסטיות אינה מתקיימת. בחרנו לבדוק זאת עבור המודל הנ"ל על ידי מבחן ברוש-פגן ומבחן ווייט. קיבלנו במבחן ווייט $P\text{-value} = 0.08086$ ובמבחן ברוש-פגן $P\text{-value} = 0.1$, לכן אנו דוחים את ההנחת ההומוסקדסטיות, כצפוי, ונבצע תיקון ווייט לשונות במודל.

נריך בנוסף 4 מודלים נפרדים לכל משתנה רקע:

$$(a1) \text{ SSP_Offer} = \alpha_0 + \alpha_1 \text{age} + v_1$$

$$(a2) \text{ SSP_Offer} = \gamma_0 + \gamma_1 \text{female} + v_2$$

$$(a3) \text{ SSP_Offer} = \omega_0 + \omega_1 \text{english} + v_3$$

$$(a4) \text{ SSP_Offer} = \delta_0 + \delta_1 \text{GPA} + v_4$$

הממצאים להלן:

a	
<pre>> coeftest(background_effects_model, vcov = vcovHC(background_effects_model,"HC1"))</pre>	
t test of coefficients:	
	Estimate Std. Error t value Pr(> t)
(Intercept)	0.869748 0.508015 1.71 0.087 .
female	-0.013074 0.027690 -0.47 0.637 .
HS_GPA	0.000708 0.003282 0.22 0.829 .
age	-0.040670 0.021527 -1.89 0.059 .
english	0.022876 0.029016 0.79 0.431 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1	

a1	a2
<pre>> age_effects_model <- lm(ssp_offer ~ age, data = ssp_and_control) > coeftest(age_effects_model, vcov = vcovHC(age_effects_model,"HC1"))</pre>	
t test of coefficients:	
	Estimate Std. Error t value Pr(> t)
(Intercept)	0.9687 0.3869 2.50 0.012 *
age	-0.0426 0.0211 -2.02 0.044 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1	
<pre>> female_effects_model <- lm(ssp_offer ~ female, data = ssp_and_control) > coeftest(female_effects_model, vcov = vcovHC(female_effects_model,"HC1"))</pre>	
t test of coefficients:	
	Estimate Std. Error t value Pr(> t)
(Intercept)	0.1978 0.0210 9.40 <0.000000000000002 ***
female	-0.0104 0.0276 -0.38 0.71 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1	

$$4. \text{ הרצנו את המודל } (b1) \text{first_sem_grade} = \alpha_0 + \alpha_1 SSP_{Offer} + \alpha_2 SFP_{Offer}$$

בתוצאות שהתקבלו נראה כי הממוצע הציונים הממוצע לסטודנטים שאינם הוקצו ל SSP או SFP הוא 65.2106 במובהקות של יותר מ-90%, ממוצע הציונים הממוצע לסטודנט שהוקצה ל SFP גבוה ב-2.1028 נקודות במובהקות של יותר מ-90%.

נציין כי הרצנו מבחן וויט לבדיקת שונות שונה, והתקבל $P\text{-value}=0.416$, לכן אנחנו מקבלים את ההנחה שהומוסקדסטיות מתקיימת במודל.

בנוסף קיבלנו שהתוספת לציון של סטודנט שהוקצה לקבוצת SSP הינה -0.0112- במובהקות נמוכה מ-90% בהרבה (ניתן לראות לפי $P\text{-value}$), לכן נסיק שהשינוי בציון סטודנט שהוקצה ל SSP לא שונה מאפס בצורה מובהקת, בדומה לתוצאות המתוארות במאמר.

כלכלית, ייתכן שבטווח הקצר, לתמריץ כלכלי השפעה חזקה יחסית לתמיכה אקדמית, בנוסף לכך במאמר מציינים כי כ-87% מהסטודנטים שהוקצו ל SFP נרשמו, לעומת כ-55% שהוקצו ל SSP שנרשמו. השפעת ההקצאה לתכנית משמעותית יותר עבור SFP כיוון שאחוז גדול יותר של מועמדים נרשמו לתכנית.

נראה שקיבלנו ערך R^2 מתוקן שגודלו 0.00356, כלומר המשתנים המסבירים מסבירים חלק קטן מאוד מההשפעות על הציון, לכן ככל הנראה יש משתנים רבים אשר לא במודל שמסבירים את השינויים בציון סוף סימסטר חורף.

5. נצפה שלכמעט כל משתנה שנבדק תהיה השפעה כלשהי על ציון הסטודנט, אם כי יש משתנים שלדעתנו ישפיעו בצורה משמעותית יותר. על מנת לברור אילו משתנים משפיעים בצורה מובהקת על ממוצע הציונים בסוף סימסטר חורף, הרצנו מודל לינארי ב- R שכולל את כל המשתנים (מלבד, signup , GPA_year1 , GPA_year2 אותם נבדוק בהמשך העבודה).

המשתני בקרה הנוספים שיצאו מובהקים שונים מאפס הינם – גיל, אישה, ממוצע ציונים בתיכון, אם דוברת אנגלית כשפת אם, מתכנן לסיים את התואר תוך 4 שנים. נריץ את המודל הבא כדי לבדוק את השפעותיהם:

$$(b2) \text{first_sem_grade} = \beta_0 + \beta_1 SSP_{Offer} + \beta_2 SFP_{Offer} + \beta_3 GPA + \beta_4 age + \beta_5 female + \beta_6 english + \beta_7 four_years + u$$

נבצע גם מבחן וויט לשונות שונה - קיבלנו $P\text{-value}=0.001 < 0.1 = \alpha$, לכן נבצע תיקון ווייט.

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	38.5631	13.2760	2.90	0.0038 **
ssp_offer	-0.3905	0.9384	-0.42	0.6774
sfp_offer	1.5650	0.8036	1.95	0.0517 .
HS_GPA	0.6848	0.0759	9.03	< 0.0000000000000002 ***
age	-1.5538	0.6698	-2.32	0.0206 *
female	-2.5905	0.6430	-4.03	0.00006 ***
english	1.9124	0.6784	2.82	0.0049 **
finish_in_4_yrs	1.4285	0.8796	1.62	0.1047

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1				

במודל $b1$ קיבלנו את המקדם - $\alpha_1 = -0.0112$ (0.9347) מול המקדם המתאים ל- SSP_Offer במודל $b2$ שיצא היה $\beta_1 = -0.3905$ (0.9347). נשים לב שבשני המודלים אומד זה אינו מובהק, אולם במודל $b2$ קיבלנו מובהקות גדולה ממודל $b1$ (התקבל t -value גבוה יותר ב- $b2$ אבל עדיין לא מובהק ב-90%). במודל $b1$ קיבלנו את המקדם - $\alpha_2 = 2.1028$ (0.9079) מול המקדם המתאים ל- SFP_Offer במודל $b2$ שיצא היה $\beta_2 = 1.5650$ (0.8036). האומדים בשני המודלים מובהקים מרמת מובהקות של 90%, אולם במודל $b2$ קיבלנו השפעה קטנה יותר של הקצאה לקבוצת SFP על ממוצע הציונים, משום שהוספו למודל משתני ביקורת אשר יצרו הטייה חיובית ב- α_2 במודל $b1$.

נשים לב שהמשתנים שהשפיעו בצורה המובהקת ביותר על ציוני הסטודנטים הן משתני הרקע, כשההשפעה הגדולה ומובהקת ביותר הינה ממוצע ציון התיכון, כשפרשנות האומד $\beta_3 = 0.6848$ היא שלכל נקודה נוספת בממוצע התיכון, בהנתן שאר המשתנים קבועים, תוביל לגידול של 0.6848 בציון החזוי אצל הסטודנט בסוף סימסטר החורף.

6. נבדוק אם להקצאה לתוכנית SFP ולתוכנית SSP יש השפעה שונה על הציון בסוף סימסטר החורף. השערת האפס תהיה שמקדמי המשתנים יהיו שווים במודל, אחרת נדחה את השערת האפס – כלומר, המשתנים שונים ויש השפעה שונה בין ההקצאה לתכניות.

$$H_0: \beta_1 = \beta_2$$

$$H_1: \beta_1 \neq \beta_2$$

נבצע מבחן F עם מגבלה אחת.

```
Model 1: restricted model
Model 2: first_sem_grade ~ ssp_offer + sfp_offer + HS_GPA + age + female +
  english + finish_in_4_yrs
```

Note: Coefficient covariance matrix supplied.

	Res.Df	Df	F	Pr(>F)
1	999			
2	998	1	3.14	0.077

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

קיבלנו $P\text{-value}=0.077 < 0.1 = \alpha$ לכן נדחה את השערת האפס. דרך נוספת ושקולה להבין את תוצאות מבחן ההשערות היא שקיבלנו $F_{stat}=3.14$ כשלפי דרגות החופש נקבל $F_{crit}=2.711$, לכן $F_{stat} > F_{crit}$ ואנחנו דוחים את השערת האפס.

כלומר, על פי תוצאות מבחן ההשערות, אנחנו דוחים את ההשערה שלהקצאה לשתי התכניות של השפעות זהות על סטודנטים התלמידים בסוף סימסטר החורף – דהיינו ברמת מובהקות של 90% יש שוני בהשפעת הקצאת הסטודנטים לקבוצות על ציוניהם בסוף סימסטר החורף.

7. הרצנו שני מודלים נוספים, בדומה למודל $b2$ כשאנחנו עדיין לוקחים בחשבון במודלים את משתני הבקרה העיקריים שמצאנו.

נשים לב שציוני הסימסטר הראשון הם בטווח 0-100, לעומת ציוני ה-GPA שבטווח בין 0-4, לכן על מנת שנוכל להשוות בין ההשפעות בסימסטר הראשון לציונים השנתיים, נכפיל את ציון ה-GPA ב-25 בכדי לקבל טווח של 0-100, כמו בציוני הסימסטר הראשון.

יצרנו שתי עמודות חדשות בנתונים, ועליהם הרצנו את הרגרסיות הבאות.

$$(c1)GPA_Year_1 = \gamma_0 + \gamma_1SSP_{Offer} + \gamma_2SFP_{Offer} + \gamma_3GPA + \gamma_4age + \gamma_5female + \gamma_6english + \gamma_7four_years + \epsilon_1$$

$$(c2)GPA_Year_2 = \mu_0 + \mu_1SSP_{Offer} + \mu_2SFP_{Offer} + \mu_3GPA + \mu_4age + \mu_5female + \mu_6english + \mu_7four_years + \epsilon_2$$

הרצנו גם מבחן ווייט לשונות שונה בשני המודלים, ובמודל השני קיבלנו שהנחת ההומוסקדסטיות אינה מתקיימת לכן ביצענו תיקון ווייט בהתאם. להלן התוצאות שהתקבלו:

מודל	אומד ל- SFP_Offer	אומד ל- SSP_Offer
סימסטר חורף	1.5650(0.8624)	-0.3905 (0.8874)
שנה ראשונה	-0.324 (1.614)	0.988 (1.66)
שנה שנייה	0.754(1.659)	1.653 (1.874)

נסיק מהממצאים בטבלה כי האומדים לא שונים מאפס באופן מובהק, למעט האומד של הקצאה ל-SFP בסימסטר הראשון. מכך, נסיק כי במודלים שהרצנו, השפעת ההקצאה לתכניות השפיעו בצורה מזערית, עד כדי אפס, לעומת האומד אותו ציינו. נראה שההשפעה של ההקצאה ל-SFP גדולה בסימסטר הראשון, ודועכת לאחר מכן עד כדי מזערית.

8. ברצוננו לבדוק האם ההקצאה לתכנית SFP השפיעה על סטודנטים עם ממוצע ציונים מעל החציון בתיכון, לעומת סטודנטים עם ממוצע ציונים הנמוך ממנו. ראשית מצאנו את החציון של ממוצעי התיכון של הסטודנטים שהוקצו ל-SFP וסטודנטים בקבוצת הביקורת. מצאנו שהחציון הינו $GDP_Median = 79.2$. לאחר מכן הגדרנו משתנה דמי בשם $Above_Med$ אשר מקבל ערך 1 אם ממוצע הציונים בתיכון של הסטודנט הוא מעל 79.2, ו-0 אחרת. אמדנו את המודל הבא:

$$(c3)first_{sem_grade} = \beta_0 + \beta_1SFP_{Offer} + \beta_2Above_{Med} + \beta_3SFP_{Offer} \times Above_{Med} + u$$

נרצה לבדוק אם יש שוני בהשפעה של SFP על ציוני הסטודנטים בין הקבוצות.

השפעת ההקצאה ל-SFP על סטודנט עם ממוצע מתחת לחציון יהיה

$$E\left(first_{sem_grade} \middle| SFP_{Offer} = 1 \text{ and } Above_{Med} = 0\right) - E\left(first_{sem_grade} \middle| SFP_{Offer} = 0 \text{ and } Above_{Med} = 0\right) = \beta_1$$

השפעת השקצאת SFP על סטודנט עם ממוצע מעל לחציון יהיה

$$E\left(first_{sem_grade} \middle| SFP_{Offer} = 1 \text{ and } Above_{Med} = 1\right) - E\left(first_{sem_grade} \middle| SFP_{Offer} = 0 \text{ and } Above_{Med} = 1\right) = \beta_3 + \beta_1$$

השערת האפס תהיה שאין הבדל בהשפעת SFP בין הקבוצות.

$$H_0: \beta_3 + \beta_1 = \beta_1 \Leftrightarrow \beta_3 = 0$$

$$H_1: \beta_3 \neq 0$$

נבצע את מבחן F ב-R עם מגבלה אחת.

קיבלנו - $P\text{-value} = 0.045 < 0.1 = \alpha$, לכן נדחה את השערת האפס – קיים הבדל מובהק בין השפעת ההקצאה ל-SFP עבור תלמידים עם ציון ממוצע בתיכון מעל ומתחת לחציון.

חלק ד: ההשפעה של השתתפות בפועל תוכניות:

9. ביצענו סינון כך שהמדגם כולל רק את הסטודנטים שהוקצו ל-SFP, כלומר $SFP_Offer=1$, ובדקנו את הממוצעים של משתני הרקע לסטודנטים שנרשמו לתכנית וסטודנטים שלא נרשמו, כשלפי המאמר אנחנו יודעים שכ 87% מסטודנטים שהוקצו ל-SFP נרשמו.

משתני רקע	לא נרשמו ל-SFP	נרשמו ל-SFP
אישה	0.45	0.618
ממוצע ציונים בתיכון	77.765	79.71
גיל	18.35	18.177
שפת אם של האם היא האנגלית	0.9	0.703

אנחנו למדים מהממוצעים שבממוצע לסטודנטים שנרשמו לתכנית יש ממוצע ציונים בתיכון גבוה בכ-2 נקודות מאלה שלא נרשמו. נוסף על כך, יחס הנשים שנרשמו גבוה בהרבה מיחס הנשים שלא נרשמו, כלומר יש יותר היענות אצל נשים להרשמה בתכנית מאשר אצל גברים. משפת האם של האם אנחנו מסיקים שמקומיים (שאמם מדברת אנגלית כשפת אם) נרשמים בממוצע פחות. הסבר לכך יכול להיות שמשפחה מבוססת נוטה להיות משפחה מקומית, כך שיש השפעה חיצונית שלא קשורה באופן ישיר לשפה. (מדובר בהשערה לא מבוססת מהנתונים). לבסוף, אין הבדל משמעותי בגילאים.

חשוב לציין כי בקבוצה שהוקצתה ל-SFP ולא נרשמה יש 20 אנשים בלבד, כך שהנתונים יכולים להיות מוטים, כי יש השפעה גדולה יותר לתוצאות קיצוניות על הממוצע.

10. נאמוד את המודל הבא:

$$(d) first_sem_grade = \beta_0 + \beta_1 SFP_Signup + u$$

תוצאות המודל כדלקמן:

```
Call:
lm(formula = first_sem_grade ~ sfp_signup, data = sfp_and_control)

Residuals:
    Min       1Q   Median       3Q      Max
-63.22  -5.55   0.78    6.91   28.78

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   65.219     0.401   162.80 <0.0000000000000002 ***
sfp_signup     2.330     0.945    2.47    0.014 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.6 on 844 degrees of freedom
Multiple R-squared:  0.00715, Adjusted R-squared:  0.00598
F-statistic: 6.08 on 1 and 844 DF, p-value: 0.0139
```

הממצאים הם שממוצע הציונים בסימסטר חורף לסטודנטים במדגם שלא נרשמו לSFP הינו $65.219(0.401)$ כשלסטודנטים שכן נרשמו לSFP יש תוספת ממוצעת לציון של $2.33(0.945)$. נשים לב שאומדים אלה מובהקים ברמת מובהקות של יותר מ-90%, אולם לדעתנו לא ניתן לפרש אותם כחסרי הטיה – כלומר לא אומדים מסבירים.

β_1 "כולל" בתוכו השפעות של משתנים שלא נלקחו בחשבון במודל, לכן הוא מוטה. לדוגמא, ראינו שלממוצע הציונים בתיכון ולהירשמות לSFP יש שונות משותפת חיובית, ו-ממוצע הציון בתיכון קשור חיובית ל $first_sem_grade$, לכן לי זה β_1 יוטה כלפי מעלה. בנוסף, ראינו כי יש הבדל משמעותי בציוני הסטודנטים שנרשמו לתכנית ואלה שלא נרשמו, כך שהחלטת הסטודנטים משפיעה על האומד שקיבלנו.

$$\widehat{Cov}(SFP_Signup, HS_GPA) > 0 : \text{מתמטית}$$

וגם ממודל b1 קיבלנו שהמקדם של HS_GPA גדול מאפס,

$$bias(\beta_1) = \tilde{\beta}_2 \frac{\widehat{Cov}(SFP_Signup, HS_GPA)}{\widehat{Var}(SFP_Signup)} > 0$$

לכן β_1 יהיה מוטה כלפי מעלה מעלה מHS_GPA.

דוגמאות נוספות למשתנים מושמטית שמטים את האומד הם – מוטבציית הסטודנט, מצב סוציו-אקונומי בבית ועוד.

11. על מנת לפתור את בעיית ההטייה במודל d, אשר לא מקיים את הנחה IV, נשתמש בהקצאה לתכנית SFP כמשתנה עזר להשתתפות בתכנית SFP.

על מנת להשתמש בהקצאה לSFP כמשתנה עזר במודל צריך שיתקיימו שלושה תנאים:

$$Cov(SFP_Offer, SFP_Signup) \neq 0 \quad (1)$$

$$Cov(SFP_Offer, u) = 0 \quad (2)$$

$$First_Sem_Grade \text{ לא משפיע בצורה ישירה על } SFP_Offer \quad (3)$$

בנוגע לשונות המשותפת של ההקצאה לSFP וההרשמה לSFP הרצנו R וקיבלנו ש $Cov(SFP_Offer, SFP_Signup) = 0.143$ לכן השונות המשותפת שונה מאפס (בפרט גדולה מ-0), כנדרש בתנאי הראשון. הסבר הגיוני לכך תהיה שככל שסטודנטים בעלי הישגים גבוהים יותר, כך הם עשויים להרשם לSFP, כמו שראינו כבר.

אם אכן החלוקה לקבוצות נעשתה בצורה אקראית, ואכן ממוצעי משתני הרקע שווה בין הקבוצות, ולא ניתן לחזות לפי משתני רקע לאיזה קבוצה סטודנט הוקצה, אז נצפה שהשונות המשותפת של ההקצאה לSFP להפרעה המקרית תהיה אפס. נשים לב שבחלק א בדקנו את ממוצעי משתני הרקע של הקבוצות, ובדקנו אם ניתן לחזות אם סטודנט הוקצה לSSP או לא, אולם לא בדקנו עבור SFP. נבדוק זאת כעת.

נריך את המודלים הבאים, עם תיקוני שונות במידת הצורך:

$$(e) SFP_Offer = \beta_0 + \beta_1 age + \beta_2 female + \beta_3 english + \beta_4 GPA + u$$

$$(e1) SFP_Offer = \alpha_0 + \alpha_1 age + v_1$$

$$(e2) SFP_Offer = \gamma_0 + \gamma_1 female + v_2$$

$$(e3) SFP_Offer = \omega_0 + \omega_1 english + v_3$$

$$(e4) SFP_Offer = \delta_0 + \delta_1 GPA + v_4$$

להלן התוצאות:

e					
t test of coefficients:					
	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	0.28378	0.49941	0.57	0.57	
female	0.01282	0.02786	0.46	0.65	
HS_GPA	0.00485	0.00325	1.49	0.14	
age	-0.02691	0.02247	-1.20	0.23	
english	0.02863	0.02965	0.97	0.33	

e1	e2
t test of coefficients:	t test of coefficients:
Estimate Std. Error t value Pr(> t)	Estimate Std. Error t value Pr(> t)
(Intercept) 0.8401 0.4085 2.06 0.04 *	(Intercept) 0.1933 0.0209 9.24 <0.000000000000002 ***
age -0.0349 0.0223 -1.56 0.12	female 0.0174 0.0279 0.62 0.53
---	---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1	Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

e3	e4
t test of coefficients:	t test of coefficients:
Estimate Std. Error t value Pr(> t)	Estimate Std. Error t value Pr(> t)
(Intercept) 0.1815 0.0240 7.57 0.000000000000099 ***	(Intercept) -0.22682 0.25672 -0.88 0.377
english 0.0315 0.0293 1.07 0.28	HS_GPA 0.00544 0.00326 1.67 0.095 .
---	---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1	Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

לפי הממצאים אנחנו רואים שלא ניתן לחזות לפי משתני הרקע במובהקות של 90% האם הסטודנט משתייך לקבוצה שהוקצאה לSFP או לא, למעט HS_GPA:

אבל, קיבלנו אומד מובהק ברמת מובהקות של 90% ל HS_GPA רק במודל כשזה המשתנה המסביר היחיד. ראינו בחלק ב שבמודלים המצומצמים ישנה הטייה מובנת, משום שאנחנו משמיטים משתנים רלוונטים, שכן במודל e קיבלנו משתנים שכולם לא מובהקים שונים מאפס. נוסף על כך, האומד שהתקבל במובהקות שונה מאפס זניח – 0.005, לכן אנחנו נסיק שההנחה $Cov(SFP_Offer, u) = 0$ אכן מתקיימת מכיוון שההקצאה נעשתה באופן אקראי.

לגבי התנאי השלישי, נראה ש SFP_Offer לא נמצא במשוואה המקורית (d), כמו כן ההשפעה של ההקצאה לקבוצה אינה משפיעה באופן ישיר על ציוני החורף, אלא ההשתתפות בתכנית (שמתואמת עם משתני העזר) משפיעה על הציונים. בכך אנחנו מקבלים את ההשפעה באופן עקיף, כפי שנדרש:

$$SFP_Offer \Rightarrow SFP_Signup \Rightarrow First_Semester_Grade$$

נאמוד את המודל עם משתני העזר בשיטת 2SLS:

שלב ראשון – נריץ רגרסיה עם ההרשמה ל SFP כמשתנה מוסבר, עם ההקצאה ל SFP כמשתנה מסביר:

$$(f1) SFP_Signup = \pi_0 + \pi_1 SFP_Offer + u$$

```
Call:
lm(formula = sfp_signup ~ sfp_offer, data = sfp_and_control)

Residuals:
    Min       1Q   Median       3Q      Max
-0.884   0.000   0.000   0.000   0.116

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 0.0000000000000486 0.0055740568832056      0.0      1
sfp_offer    0.88372093023253417 0.01236210291631237     71.5 <0.0000000000000002 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.145 on 844 degrees of freedom
Multiple R-squared:  0.858,    Adjusted R-squared:  0.858
F-statistic: 5.11e+03 on 1 and 844 DF,  p-value: <0.0000000000000002
```

קיבלנו ש β_1 שונה מאפס במובהקות של 90% (לפי ה P-value).

שמרנו את הערך המנובא של SFP_Signup לפי המשוות f1 במשתנה $\widehat{SFP_Signup}$ ואמדנו את משוואת **השלב השני** כפונקציה של המשתנה המנובא.

$$(f2) first_sem_grade = \beta_0 + \beta_1 \widehat{SFP_Signup} + u$$

בדקנו עם מבחן וויט אם הנחת ההומוסקדסטיות מתקיימת, וקיבלנו P-value=0.397 לכן לא ביצענו תיקון לשונות שונה. להלן התוצאות:

```
Call:
lm(formula = first_sem_grade ~ sfp_signup_hat, data = sfp_and_control)

Residuals:
    Min       1Q   Median       3Q      Max
-63.21  -5.49   0.79   6.79  28.79

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    65.211     0.407  160.35 <0.0000000000000002 ***
sfp_signup_hat   2.380     1.021   2.33    0.02 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.6 on 844 degrees of freedom
Multiple R-squared:  0.0064,    Adjusted R-squared:  0.00522
F-statistic: 5.44 on 1 and 844 DF,  p-value: 0.02
```

בתוצאות הרגרסיה קיבלנו שתוספת הציון במוצע בסוף סימסטר חורף לסטודנט שנרשם ל-SFP, עם המשתנה עזר, הינו 2.38, במובהק שונה מ-0 ברמת מובהקות של 90%. כלומר, $\beta_1 = 2.38$

אמדנו את אומד זה גם בשיטת IV, באופן הבא:

$$\beta_1^{IV} = \frac{Cov(SFP_Offer, First_Semester_Grade)}{Cov(SFP_Offer, SFP_Signup)}$$

מכיוון שאמדנו מודל עם משתנה מוסבר אחד, ציפינו לקבל β_1 זהה בשתי שיטות האמידה, ואכן קיבלנו ש $\beta_1^{IV} = 2.38$, כלומר המודלים הניבו אמידה זהה להשפעה של התכנית SFP על הציונים, לפי משתנה העזר SFP_Offer.

מכיוון שהשתמשנו באמידה עם משתנה עזר המקיים את שלושת התנאים הנ"ל, אנו מקבלים השפעה סיבתית – כלומר ההשפעה הסיבתית שיש לתכנית על ציוני הסימסטר הראשון הינה 2.38 נקודות.

סיכום:

בעבודה זה בדקנו את ההשפעה של תמיכה אקדמית וכלכלית על הישגי סטודנטים בקולג' על בסיס המחקר. ראשית בדקנו את שאלת המחקר, והראנו את החשיבות של ניסוי מבוקר על מנת לאמוד מודל אשר מסביר את ההשפעות של התכניות על הציונים. בדקנו עד כמה המודל היה מבוקר, נתחנו את ממצאי משתני הרקע בכל קבוצה והשפעתם על ההקצאות. מצאנו שההקצאה נעשתה באופן אקראי, והקבוצות דומות ברוב משתני הרקע (למעט הבדל קטן בגיל).

בחלק ג', ביצענו ניתוחים של השפעת תכניות התמיכה על ציוני הסטודנטים. הרצנו מודלים נפרדים לכל קבוצה ובחנו את ההשפעה היחסית של כל סוג תמיכה כל ציוני הסמסטר הראשון, וגם על הציונים בהמשך. הוספנו משתנים מסבירים נוספים למודל כשהנחנו שהם משפיעים על אפקט התכניות בכל הציונים. בחלק ד', התמקדנו בהשפעת ההשתתפות בתכנית SFP על הציונים, ראינו שהמשתנה אנדוגני לכן השתמשנו בהקצאה לתכנית המשתנה עזר אקסוגני, והשתמשנו בו על מנת לבדוק את השפעת התכנית על ציוני סימסטר חורף.

התוצאות מראות שלתמריצים כלכליים יש השפעה חזקה יחסית בטווח הקצר, לעומת השפעת התמיכה האקדמית שאינה מובהקת סטטיסטית. במסקנות המחקר התקבל כי ההשפעה של תכנית SFSP מובהקת יותר בקרב נשים, ובעבודה לא התייחסנו ל-SFSP, עם זאת ראינו שלקבוצת SFSP שיעור ההרשמה בקרב נשים הייתה גבוהה יותר, וכן השפעת התכנית על ציוניהם של הסטודנטים הייתה חיובית מובהקת. לכן, נסיק מסקנה הדומה למאמר, שלפי הנתונים לתמריצים כלכליים השפעה חיובית על ציוני סטודנטים. השפעה זו גדלה בקרב נשים.

נציין כי הנתונים הם ממחקר מאוניברסיטה אחת, בשנה ספציפית, כך שאין התייחסות לאפקטים הקבועים המשתנים בין קולג'ים שונים ובין שנים שונות. לכן, על מנת לדייק את ממצאי העבודה, היינו עורכים מדגם גדול יותר, בבתי ספר שונים על פני מספר רב של שנים.

נסכם ונאמר שיש השפעה סיבתית של תמיכה כלכלית על ציוניהם של סטודנטים, אשר הולכת וקטנה עם הזמן.

```

options(scipen = 999)
options(digits = 5)
setwd("C:/Users/omrid/Desktop/TAU/Second year/First_semester/Econometrics 101/Final project/WhatHelpsStudentsMore/Data")
library(tidyverse)
library(car)
library(sandwich)
library(lmtest)
library(whitestrapp)
df <- read.csv("term_paper_data.csv")

#####
#Part 2
#####

#Question 1

#First we will split the data into the three groups(without SFSP group):
#SSP:
ssp <- df %>% filter(ssp_offer==1)
#SFP:
sfp <- df %>% filter(sfp_offer==1)
#Control:
control <- df %>% filter(control==1)

#Now we will hold the avg for Female , GPA , age , whether or not mother's tongue is English.

#SSP:
ssp_mean_Female <- mean(ssp$female)
ssp_mean_GPA <- mean(ssp$HS_GPA)
ssp_mean_age <- mean(ssp$age)
ssp_mean_english <- mean(ssp$english)
print(ssp_mean_Female)

#SFP:
sfp_mean_Female <- mean(sfp$female)
sfp_mean_GPA <- mean(sfp$HS_GPA)
sfp_mean_age <- mean(sfp$age)
sfp_mean_english <- mean(sfp$english)

#Control:
control_mean_Female <- mean(control$female)
control_mean_GPA <- mean(control$HS_GPA)
control_mean_age <- mean(control$age)
control_mean_english <- mean(control$english)
print(control_mean_age)

#All_together:
all_mean_Female <- mean(df$female)
all_mean_GPA <- mean(df$HS_GPA)
all_mean_age <- mean(df$age)
all_mean_english <- mean(df$english)

```

#Question 3 :

```
ssp_and_control <- df %>% filter(ssp_offer==1 | control==1)
#Although we know that in LPM model the Homoskedasticity assumption doesn't accure, we ran white and BP test just to make sure.
background_effects_model <- lm(ssp_offer ~ female + HS_GPA + age + english, data = ssp_and_control)
summary(background_effects_model)
```

#We want to check Heteroskedasticity:

#Breusch-Pagan test:

```
ssp_and_control$u_hat <- residuals(background_effects_model)
ssp_and_control$u_hat_sq <- (ssp_and_control$u_hat)^2
bp_model <- lm(u_hat_sq ~ female + HS_GPA + age + english, data = ssp_and_control)
summary(bp_model)
```

#White Test

```
white_test(background_effects_model)
```

#We found that there is heteroskedasticity ($E[u|x] \neq u_hat$)

#Now we need to fix this using white correction.

```
coeftest(background_effects_model, vcov = vcovHC(background_effects_model,"HC1"))
```

#Now we will check for each individual variable, and do white correction for them.

```
age_effects_model <- lm(ssp_offer ~ age, data = ssp_and_control)
coeftest(age_effects_model, vcov = vcovHC(age_effects_model,"HC1"))
```

```
HS_GPA_effects_model <- lm(ssp_offer ~ HS_GPA, data = ssp_and_control)
coeftest(HS_GPA_effects_model, vcov = vcovHC(HS_GPA_effects_model,"HC1"))
```

```
female_effects_model <- lm(ssp_offer ~ female, data = ssp_and_control)
coeftest(female_effects_model, vcov = vcovHC(female_effects_model,"HC1"))
```

```
english_effects_model <- lm(ssp_offer ~ english, data = ssp_and_control)
coeftest(english_effects_model, vcov = vcovHC(english_effects_model,"HC1"))
```

#####

#Part 3

#####

#Question 4

```
SFP_vs_SSP_first_sem_model <- lm(first_sem_grade ~ ssp_offer + sfp_offer, data = df)
```

```
summary(SFP_vs_SSP_first_sem_model)
```

#White Test

```
white_test(SFP_vs_SSP_first_sem_model)
```

#Question 5

#To check which variables affect the most on the grade, we created a big linear model that takes into account all the possible vars

```
all_affects_on_grade_model <- lm(first_sem_grade ~ ssp_offer + sfp_offer + HS_GPA + age + female + english + dad_HS_grad +
dad_college_grad + mom_HS_grad + mom_college_grad +
uni_first_choice + finish_in_4_yrs + grad_degree + live_home + work_plans + last_min, data = df)
summary(all_affects_on_grade_model)
```

#Now we will take only those that we found they are distinct statistically to affect the grades.

```
distinct_affects_on_grade_model <- lm(first_sem_grade ~ ssp_offer + sfp_offer + HS_GPA + age + female + english + finish_in_4_yrs, data =
df)
summary(distinct_affects_on_grade_model)
```

```

#Now we will check for Homoskedasticity using white test
white_test(distinct_affects_on_grade_model)
#We found that P-value is lower then 0.1 so we will do the white correction
fixed_distinct_affects_on_grade_model <- vcovHC(distinct_affects_on_grade_model,"HC1")

#Question 6

linearHypothesis(distinct_affects_on_grade_model, "sfp_offèr = ssp_offèr",vcov=fixed_distinct_affects_on_grade_model)

critical_f_value <- qf(0.9, 1, 998)

#Question 7

#Assuming that the same 5 variables are the distinct ones even after one year and two years:
#We will run the same model as we ran for one semester, for the end of first year and end of second year.
#BUT! we have a difference between the grades in first semester(in range 0-100) and the grades in first year in second year(in range 0-4):
#So We create another column with 25 * grade to get 0-100 range.
df$year_1_GPA_times_25 <- 25*df$GPA_year1
distinct_affects_on_grade_first_year_model <- lm(year_1_GPA_times_25~ssp_offèr + sfp_offèr+ HS_GPA + age + female + english +
finish_in_4_yrs, data = df )
summary(distinct_affects_on_grade_first_year_model)
#We will check using white test for Homoskedasticity:
white_test(distinct_affects_on_grade_first_year_model)
#we found that there is Homoskedasticity
summary(distinct_affects_on_grade_first_year_model)

#Now we will do the same for second year
df$year_2_GPA_times_25 <- 25*df$GPA_year2
distinct_affects_on_grade_second_year_model <- lm(year_2_GPA_times_25~ssp_offèr + sfp_offèr+ HS_GPA + age + female + english +
finish_in_4_yrs, data = df )

white_test(distinct_affects_on_grade_second_year_model)
#We found that there is heteroskedasticity so we will do the white correction
coeftest(distinct_affects_on_grade_second_year_model, vcov = vcovHC(distinct_affects_on_grade_second_year_model,"HC1"))

#Question 8
#We will first check median of the HS_GPA of students in the sfp + control groups.
sfp_and_control <- df %>% filter(sfp_offèr==1 | control==1)

median_HS_GPA <- median(sfp_and_control$HS_GPA, na.rm = TRUE)

sfp_and_control <- sfp_and_control %>%
mutate(above_median = ifelse(HS_GPA > median_HS_GPA, 1, 0))

#Now we will create the linear model that will show the affect of SFP on the grades according to the 2 groups:
#1) above the median in High school
#2) below the median in High school

above_and_below_median_model <- lm(first_sem_grade ~ sfp_offèr * above_median, data = sfp_and_control)
summary(above_and_below_median_model)

white_test(above_and_below_median_model)
#We found that there is no need for white correction.
#Now we will check out hypotesys that B3 is 0 (above*SFP)
linearHypothesis(above_and_below_median_model, "sfp_offèr: above_median = 0")
#####
#Part 4
#####
#Question 9

```


#We will create a new df that holds all of the students that were offered with SFP.

```
only_sfp_offered <- df %>% filter(sfp_offer==1)
```

#Now we will calc the means of the background variables for each group

#Group 1 - signed up for SFP

#Group 2 - Didn't sign to SFP

```
group_1 <- only_sfp_offered %>% filter(sfp_signup==1)
```

```
female_mean_signup<-mean(group_1$female)
```

```
GPA_mean_signup<-mean(group_1$HS_GPA)
```

```
english_mean_signup<-mean(group_1$english)
```

```
age_mean_signup<-mean(group_1$age)
```

```
group_2 <- only_sfp_offered %>% filter(sfp_signup==0)
```

```
female_mean_not_signup<-mean(group_2$female)
```

```
GPA_mean_not_signup<-mean(group_2$HS_GPA)
```

```
english_mean_not_signup<-mean(group_2$english)
```

```
age_mean_not_signup<-mean(group_2$age)
```

#Question 9

#First we will take the SFP and control group to look at.

```
sfp_and_control <- df %>% filter(sfp_offer==1 | control==1)
```

#Question 10:

#Now we will run the model that was requested.

```
grade_for_sfp_signup_model <- lm(first_sem_grade ~ sfp_signup, data = sfp_and_control)
```

```
summary(grade_for_sfp_signup_model)
```

#Question 11:

```
covariance <- cov(sfp_and_control$sfp_signup, sfp_and_control$sfp_offer)
```

```
sfp_and_control <- df %>% filter(sfp_offer==1 | control==1)
```

#Although we know that in LPM the Homoskedasticity assumption doesn't accure, we ran white and BP test just to make sure.

```
background_effects_model <- lm(sfp_offer ~ female + HS_GPA + age + english, data = sfp_and_control)
```

```
summary(background_effects_model)
```

#We want to check Heteroskedasticity:

#Breusch-Pagan test:

```
sfp_and_control$u_hat<-residuals(background_effects_model)
```

```
sfp_and_control$u_hat_sq<- (sfp_and_control$u_hat)^2
```

```
bp_model <- lm(u_hat_sq ~ female + HS_GPA + age + english, data = sfp_and_control)
```

```
summary(bp_model)
```

#White Test

```
white_test(background_effects_model)
```

#We found that there is heteroskedasticity ($E[u_i] \neq u_hat$)

#Now we need to fix this using white correction.

```
coeftest(background_effects_model, vcov = vcovHC(background_effects_model,"HC1"))
```

#Now we will check for each individual variable, and do white correction for them.

```
age_effects_model <- lm(sfp_offer ~ age, data = sfp_and_control)
```

```
coeftest(age_effects_model, vcov = vcovHC(age_effects_model,"HC1"))
```

```
HS_GPA_effects_model <- lm(sfp_offer ~ HS_GPA, data = sfp_and_control)
```

```
coeftest(HS_GPA_effects_model, vcov = vcovHC(HS_GPA_effects_model,"HC1"))
```

```
female_effects_model <- lm(sfp_offer ~ female, data = sfp_and_control)
```

```
coeftest(female_effects_model, vcov = vcovHC(female_effects_model,"HC1"))
```

```
english_effects_model <- lm(sfp_offer ~ english, data = sfp_and_control)
```

```
coeftest(english_effects_model, vcov = vcovHC(english_effects_model,"HC1"))
```

```

#Now we will do the 2sls test:
two_sls_first_step <- lm(sfp_signup~sfp_offer, data=sfp_and_control)
summary(two_sls_first_step)

sfp_and_control$sfp_signup_hat <- fitted.values(two_sls_first_step)

two_sls_second_step <- lm(first_sem_grade~sfp_signup_hat, data = sfp_and_control)

white_test(two_sls_second_step)
#White test did not find heteroskedasticity so we won't fix this.
summary(two_sls_second_step)
#Now we will do this using the IV variable
offer_to_grade <- cov(sfp_and_control$sfp_offer, sfp_and_control$first_sem_grade)
offer_to_signup <- cov(sfp_and_control$sfp_offer, sfp_and_control$sfp_signup)
beta_IV <- offer_to_grade / offer_to_signup

beta_IV

```